

Documento de Diseño v1 · Cloud Provider Analytics

Primera entrega · 05/10/2026 · ITBA · Big Data 2C 2026

Integrantes: Valentina Marti Reta · Nicanor Porto · Matías Coleur · Federico Etchegorry · Julieta Techenski

Documento de diseño de la primera evaluación. Las decisiones citadas (D1 a D12) están en [decisions.md](#) y la evidencia medida, en [../evidence/profiling_landing.md](#).

1. Interpretación del problema

1.1 Problema

El equipo actúa como área de datos de un proveedor de nube. Tres áreas de negocio —FinOps, Soporte y Producto— necesitan analítica sobre los datos de sus clientes, pero las fuentes llegan crudas y no son consultables de forma directa: siete maestros en CSV y un flujo de eventos de uso fragmentado en 120 archivos JSONL, con nulos, tipos ambiguos, valores fuera de rango y un cambio de esquema a mitad del histórico (la versión 2 incorpora `carbon_kg` y `genai_tokens`).

El problema es construir un pipeline que ingeste, limpie, conforme y publique esos datos con dos capacidades complementarias:

Capacidad	Datos	Necesidad que cubre
Near real-time	Eventos de uso (<code>usage_events_stream</code>)	Métricas operativas de uso, consumo y costo incremental
Batch diario o mensual	Maestros de CRM, tickets, encuestas y facturación	Dimensiones de referencia, soporte y revenue

El resultado son marts analíticos en Parquet, publicados en Cassandra/AstraDB, que responden las preguntas de cada área sin acceder a los datos crudos.

1.2 Usuarios

Usuario	Qué necesita	Actualización	Fuentes
FinOps	Costos, consumo, revenue, créditos, impuestos y anomalías por organización y servicio	Costos de uso: near real-time · Revenue: mensual	<code>usage_events_stream</code> , <code>billing_monthly.csv</code> , <code>resources.csv</code> , <code>customers_orgs.csv</code>
Soporte	Volumen de tickets, severidad, cumplimiento de SLA y CSAT por organización y fecha	Diaria	<code>support_tickets.csv</code> , <code>customers_orgs.csv</code>
Producto / Usage	Uso de servicios, requests, métricas operativas, tokens GenAI y carbono	Near real-time	<code>usage_events_stream</code> , <code>resources.csv</code>

`users.csv` , `marketing_touches.csv` y `nps_surveys.csv` se ingestan a Bronze como fuentes de referencia; ninguna de las cinco consultas obligatorias depende de ellas.

1.3 Preguntas principales

Son las cinco consultas obligatorias de la consigna (§7.4). Cada una se responde desde una tabla de serving propia (D8).

#	Pregunta	Usuario	Fuente	Mart en Gold	Ingesta
P1	¿Cuánto costó y cuántos requests tuvo cada organización, por servicio y por día, en un rango de fechas?	FinOps	<code>usage_events_stream</code>	<code>org_daily_usage_by_service</code>	Streaming

#	Pregunta	Usuario	Fuente	Mart en Gold	Ingesta
P2	¿Cuáles son los N servicios de mayor costo acumulado de una organización en los últimos 14 días?	FinOps	usage_events_stream	org_daily_usage_by_service	Streaming
P3	¿Cómo evolucionaron los tickets críticos y la tasa de incumplimiento de SLA, por día, en los últimos 30 días?	Soporte	support_tickets.csv	tickets_by_org_date	Batch
P4	¿Cuál fue el revenue mensual de cada organización, con créditos e impuestos, normalizado a USD?	FinOps	billing_monthly.csv	revenue_by_org_month	Batch
P5	¿Cuántos tokens GenAI consumió cada organización por día y a qué costo estimado?	Producto	usage_events_stream (v2)	genai_tokens_by_org_date	Streaming

Además, FinOps requiere identificar costos diarios anómalos por organización y servicio. Se resuelve en Gold con `cost_anomaly_mart` (D9).

1.4 Objetivos medibles y criterios de éxito

El proyecto cumple su propósito cuando se alcanzan las siete metas siguientes. Las metas se expresan sobre el dataset provisto; las cifras de referencia están medidas en `evidence/profiling_landing.md`.

#	Objetivo	Métrica	Meta	Verificación	Entrega
O1	Responder las preguntas del negocio desde el serving	Preguntas P1–P5 respondidas en Cassandra/AstraDB leyendo una sola partición, sin <code>ALLOW FILTERING</code>	5 de 5	CQL y salida de cada consulta	2. ^a (P1 y P2) · final (P3 a P5)
O2	Ingestar los eventos sin pérdida	Eventos de Landing presentes en Bronze	43.200 de 43.200	Conteo Landing contra Bronze	2. ^a
O3	Ingestar los maestros sin pérdida	Filas de los 7 CSV presentes en Bronze	4.112 de 4.112	Conteo por fuente	2. ^a (3 maestros) · final (7)
O4	No perder registros entre zonas	Fechas que cumplen <code>bronze = silver + quarantine</code>	60 de 60	Conteo por <code>event_date</code> (D10)	2. ^a
O5	Aplicar las reglas de calidad	Reglas de D7 cuyo conteo de violaciones coincide con el medido en el perfilado	7 de 7	Conteo por regla en Silver y Quarantine	2. ^a (3 reglas) · final (7)
O6	Reprocesar sin duplicar	Diferencia de filas por zona entre dos ejecuciones consecutivas · <code>event_id</code> duplicados	0 · 0	Conteos antes y después de re-ejecutar	2. ^a
O7	Mantener las métricas de uso en near real-time	Micro-lotes hasta que un archivo de eventos queda disponible en Bronze	1, con trigger de 10 s	Progreso de la consulta de streaming	2. ^a

La trazabilidad de cada objetivo con el componente que lo cumple está en la parte D de `matriz_requisito_componente.md`.

2. Justificación de Big Data · las 5V

El dataset provisto es una muestra de 12,6 MB y por sí solo no requiere Big Data. La necesidad surge de la escala del caso real, que se proyecta como supuesto, y de que cada dimensión ya obliga a tomar una decisión de arquitectura sobre la muestra.

V	Hoy (medido)	A escala real (supuesto)	Decisión que lo responde
Volumen	43.200 eventos · 4.112 filas maestras · 12,6 MB	1 evento/recurso/minuto × 1 M recursos ⇒ ~1.440 M eventos/día ≈ 400 GB/día	Parquet columnar particionado (D3)

V	Hoy (medido)	A escala real (supuesto)	Decisión que lo responde
Velocidad	120 micro-lotes de 360 eventos	Ingesta continua; FinOps necesita el costo del día en curso	Structured Streaming (D1, D6)
Variedad	JSONL con 2 esquemas + 7 CSV + tags_json anidado	Se suman logs, métricas de infra, telemetría	Esquema explícito unificado (D5)
Veracidad	3,03 % tipos ambiguos · 4,72 % unit nulo · 100 % FX inconsistente en USD	Los mismos defectos en millones de filas	7 reglas + Quarantine (D7)
Valor	5 marts para 3 dominios	Alertas de sobrecosto, forecast, churn	Gold + serving Cassandra (D8)

3. Inventario y perfil de fuentes

Perfil medido sobre el dataset completo con notebooks/01_profiling_landing.ipynb : 47.312 filas, 12,6 MB y 60 días de eventos (03/07/2025 a 31/08/2025).

3.1 Inventario

Fuente	Grano	Filas	Columnas	Clave	Frecuencia
usage_events_stream/*.jsonl	1 evento de uso	43.200 en 120 archivos	11 en v1 · hasta 13 en v2	event_id	Continua, en micro-lotes
customers_orgs.csv	1 organización	80	11	org_id	Batch diario
users.csv	1 usuario	800	7	user_id	Batch diario
resources.csv	1 recurso cloud	400	7	resource_id	Batch diario
support_tickets.csv	1 ticket	1.000	8	ticket_id	Batch diario
marketing_touches.csv	1 interacción de marketing	1.500	7	touch_id	Batch diario
nps_surveys.csv	1 encuesta por organización y fecha	92	4	org_id + survey_date	Batch diario
billing_monthly.csv	1 factura por organización y mes	240	8	invoice_id	Batch mensual

Tipos. Los CSV no declaran tipos: se leen con esquema explícito y se tipifican en Bronze. Las fechas vienen en formato ISO 8601 y los booleanos como texto (True / False). En los eventos, timestamp está en ISO 8601 UTC y value llega con tres tipos: número (41.014), texto numérico (1.309) y nulo (877).

3.2 Calidad y riesgos

Fuente	Calidad medida	Tratamiento	Riesgo si no se trata
usage_events_stream	value como texto en 3,03 % · unit nulo con value presente en 4,72 % · 211 costos menores a -0,01 · dos versiones de esquema	D4, D5, D7	Nulos silenciosos al tipar y métricas incompletas
customers_orgs.csv	nps_score nulo en 13,8 % y 1 valor fuera de rango (101)	D7	NPS promedio distorsionado
users.csv	last_login nulo en 17,4 %	Se conserva nulo	Contiene email, un dato personal
resources.csv	tags_json nulo en 20,8 %	Se conserva nulo	Bajo
support_tickets.csv	resolved_at nulo en 24,0 % · csat nulo en 25,4 % y 40 valores fuera de [1,5]	D7; resolved_at nulo indica ticket abierto	CSAT promedio distorsionado

Fuente	Calidad medida	Tratamiento	Riesgo si no se trata
marketing_touches.csv	Sin nulos	—	Bajo
nps_surveys.csv	nps_score nulo en 20,7 % · comment nulo en 10,9 %	Se conservan nulos	Bajo
billing_monthly.csv	credits nulo en 57,1 % · 160 de 160 facturas en USD con tipo de cambio distinto de 1 · 13 subtotales negativos	D7; credits nulo se interpreta como 0; los subtotales negativos son notas de crédito y se conservan	Revenue distorsionado hasta ±15 %

Trazabilidad. No hay claves primarias duplicadas en ninguna de las ocho fuentes. Las seis fuentes que referencian organizaciones lo hacen por `org_id`, sin huérfanos. Los 400 `resource_id` de los eventos existen en `resources.csv`, y ningún evento tiene `org_id`, `service` o `region` distintos de los de su recurso. Desde Bronze, cada fila conserva `source_file` e `ingest_ts` (D11).

4. Arquitectura v1 y patrón elegido

Cloud Provider Analytics · Arquitectura v1

Patrón Lambda · PySpark + Structured Streaming + Parquet + Cassandra/AstraDB

ITBA · Big Data 2C 2026
Primera entrega · 05/10/2026




Diagrama v1 del 05/10/2026. El fuente editable es `arquitectura_v1.svg`.

4.1 Patrón: Lambda (D1)

Patrón	Evaluación para este caso	Resultado
Solo batch	No cubre el streaming de eventos que exige la consigna ni el costo incremental del día en curso	Descartado
Kappa	Obliga a convertir siete CSV estáticos en streams sintéticos; <code>billing_monthly</code> tiene tres cortes mensuales	Descartado
Híbrido	La definición de Lambda de la consigna (§4.3) ya describe esta separación; no hay una combinación adicional que justificar	No necesario
Lambda	Streaming para <code>usage_events_stream</code> y batch para los siete maestros; las dos ramas convergen en Bronze	Elegido

El riesgo de Lambda es duplicar lógica entre las dos ramas. Se mitiga con funciones de conformance únicas en `src/common/`, que importan los dos jobs.

4.2 Componentes y responsabilidades

Capa	Herramienta	Responsabilidad	Decisión
Fuentes	Archivos CSV y JSONL en Landing	Dato crudo inmutable	D10
Ingesta batch	PySpark 3.5 (<code>spark.read</code>)	Leer los siete maestros con esquema explícito, deduplicar por clave y agregar columnas técnicas	D2, D11
Ingesta streaming	Structured Streaming	Leer los eventos en micro-lotes con watermark, deduplicación por <code>event_id</code> y checkpoint	D4, D5, D6
Data Lake	Parquet sobre Google Drive	Zonas Bronze, Silver, Gold y Quarantine	D3, D10, D12
Procesamiento	PySpark, API de DataFrames	Conformar, aplicar reglas de calidad, calcular métricas, anomalías y marts	D7, D9
Serving	Cassandra / AstraDB	Una tabla por consulta, con <code>org_id</code> como partition key	D8
Consumo	Consultas CQL desde notebook	Responder P1 a P5 para FinOps, Soporte y Producto	D8

El entorno es Google Colab con `master("local[*]")` (D2). La solución usa únicamente la API de DataFrames, particionado explícito y Parquet, por lo que el mismo código corre distribuido en un clúster sin reescribirse.

4.3 Capacidades transversales

Capacidad	Cómo se implementa	Decisión
Gobierno	Áreas de responsabilidad por integrante (§10) y registro de decisiones versionado	—
Calidad	Siete reglas verificables; los registros rechazados van a Quarantine con la regla que los rechazó	D7
Metadatos	Columnas técnicas por zona, esquemas explícitos y registro de corridas	D11
Linaje	<code>source_file</code> por fila y registro de corridas por tabla	D11
Seguridad y accesos	Configuración externalizada sin credenciales; token de AstraDB por variable de entorno; repositorio privado; el <code>email</code> de <code>users.csv</code> no se publica en Gold ni en serving	—
Observabilidad	Filas leídas, escritas y rechazadas y duración de cada corrida	D11
Idempotencia	Checkpoints, <code>overwrite</code> dinámico por partición y anti-join contra Bronze	D6, D10
Reproducibilidad	Dataset versionado, configuración de ejemplo y README con los pasos de ejecución	D10
Versionado	Git, con un tag por entrega	—

5. Diseño del Data Lake

5.1 Zonas y formatos

Zona	Responsabilidad	Formato	Escritura
Landing	Archivos originales, inmutables	CSV y JSONL	Ninguna: solo lectura
Bronze	Mismo grano que la fuente, tipificación explícita, deduplicación y columnas técnicas	Parquet	append desde streaming · overwrite en maestros
Silver	Conformado: casteo, normalización, joins y reglas de calidad	Parquet	overwrite dinámico por partición
Gold	Marts de negocio por dominio	Parquet	overwrite dinámico por partición
Quarantine	Registros rechazados, con la regla que los rechazó	Parquet	overwrite dinámico por partición

`_checkpoints/` y `_metadata/` quedan fuera de las zonas: guardan estado del motor y registro de corridas, no datos (D10, D11). Parquet es el formato intermedio que fija la consigna y el preferido para analítica por ser columnar (clase 03).

5.2 Particionamiento (D3)

Los eventos se particionan por `event_date` y `billing_monthly` por `month`. El resto de los maestros no se particiona y se escribe con `coalesce(1)`.

Esquema	Particiones	Filas/partición	Tamaño/archivo
Sin partición	1	43.200	~1,5 MB
Por <code>event_date</code>	60	~720	~28 KB
Por <code>event_date</code> × <code>service</code>	360	~120	~5 KB
Por <code>event_date</code> × <code>service</code> × <code>region</code>	2.520	~17	<1 KB

Particionar por servicio multiplica por seis la cantidad de archivos sin ganar poda: las cinco consultas obligatorias filtran por organización y fecha, y ninguna por servicio solo. Tampoco se particiona por `org_id` (4.800 particiones de 9 filas): `org_id` es la clave de partición en Cassandra (D8), no en el lago. Los archivos resultantes son chicos frente a un bloque HDFS de 128 MB; se acepta ese costo a cambio de poda temporal y se compacta Bronze con un job posterior.

5.3 Naming (D12)

Elemento	Convención	Ejemplo
Ruta	<code><zona>/<tabla>/<columna>=<valor>/</code>	<code>bronze/usage_events_stream/event_date=2025-07-03/</code>
Tabla en Bronze	Nombre de la fuente, sin extensión	<code>bronze/billing_monthly/</code>
Tabla en Silver	Entidad conformada; prefijo <code>dim_</code> para dimensiones	<code>silver/usage_events/</code> , <code>silver/dim_org/</code>
Tabla en Gold	Nombre del mart de la consigna (D10)	<code>gold/org_daily_usage_by_service/</code>
Tabla en Quarantine	Tabla de origen, particionada por regla	<code>quarantine/usage_events_stream/dq_rule=value_not_castable/</code>
Columna	Sufijo según el tipo de dato: <code>_ts</code> , <code>_date</code> , <code>_usd</code> , <code>_raw</code>	<code>ingest_ts</code> , <code>event_date</code> , <code>daily_cost_usd</code> , <code>exchange_rate_raw</code>

5.4 Retención (D12)

Zona	Retención	Justificación
Landing	Indefinida	Es inmutable (consigna §4.2) y la única copia desde la que se reconstruyen las demás zonas
Bronze	13 meses	Se regenera desde Landing; 13 meses permiten comparar un mes con el mismo mes del año anterior sin reingestar
Silver	13 meses	Se regenera desde Bronze; mismo horizonte que Bronze para que el reproceso de una fecha sea siempre posible
Gold	Indefinida	Es agregado y chico (11.050 filas en el mart diario para 60 días) y contiene el histórico de revenue
Quarantine	90 días	Plazo para revisar el rechazo, corregir la regla o la fuente y reprocesar
<code>_checkpoints/</code>	Mientras exista la consulta de streaming	Borrarlo hace que el stream vuelva a leer Landing desde el inicio; solo se borra en un reproceso completo
<code>_metadata/</code>	Indefinida	Una línea por corrida; su tamaño es despreciable

La retención se aplica borrando particiones completas por `event_date`, sin reescribir archivos. Se define para la operación a escala real: el dataset provisto cubre 60 días y ninguna política llega a aplicarse sobre él.

5.5 Metadatos (D11)

Los metadatos se registran en tres niveles: columnas técnicas por registro, esquemas explícitos versionados en el repositorio y un registro de corridas en `_metadata/runs/`. No se usa metastore: las tablas se referencian por ruta.

Zona	Columnas técnicas	Qué permiten
Landing	Ninguna: los archivos no se modifican	El nombre y la ruta del archivo son el metadato
Bronze	<code>ingest_ts</code> , <code>source_file</code>	Saber cuándo y desde qué archivo entró cada fila
Silver	Las de Bronze y <code>dq_flags</code>	Conservar el origen y saber qué reglas de D7 marcaron la fila
Quarantine	Las de Bronze, <code>dq_rule</code> y <code>rejected_ts</code>	Saber qué regla rechazó cada fila y cuándo
Gold	<code>processed_ts</code>	Saber cuándo se calculó cada fila del mart

5.6 Reglas de promoción (D10)

Promoción	Condición	Verificación
Landing → Bronze	Esquema explícito aplicado y clave sin duplicados	Conteo de Landing igual al de Bronze (O2, O3)
Bronze → Silver	Reglas de D7 aplicadas; los registros bloqueados van a Quarantine	<code>bronze[d] = silver[d] + quarantine[d]</code> para cada fecha (O4)
Silver → Gold	La fecha está completa en Silver	La igualdad anterior se cumple para esa fecha
Gold → Cassandra	El mart de la fecha está escrito en Gold	Upsert por clave primaria; re-ejecutar no duplica (O6)

La promoción escribe con `overwrite` por partición (`partitionOverwriteMode=dynamic`), lo que permite reprocesar una fecha sin borrar el histórico.

6. Flujos batch y streaming

6.1 Flujo batch · maestros y facturación

Paso	Operación	Herramienta	Salida
1 · Lectura	Los siete CSV de Landing, con <code>StructType</code> explícito y sin <code>inferSchema</code>	<code>spark.read.csv</code>	DataFrame tipado
2 · Bronze	Deduplicación por clave primaria; columnas <code>ingest_ts</code> y <code>source_file</code> ; <code>coalesce(1)</code> , y <code>billing_monthly</code> particionado por <code>month</code>	PySpark · Parquet	<code>bronze/<fuente>/</code>
3 · Silver	Casteo de números y fechas; reglas de D7 (tipo de cambio de USD a 1, <code>csat</code> y <code>nps_score</code> fuera de rango); <code>credits</code> nulo como 0	PySpark · Parquet	<code>silver/</code>
4 · Gold	<code>revenue_by_org_month</code> y <code>tickets_by_org_date</code>	PySpark · Parquet	<code>gold/<mart>/</code>
5 · Serving	Carga con upsert por clave primaria	Conector de Cassandra para Spark	Tablas de D8

6.2 Flujo streaming · eventos de uso

Paso	Operación	Herramienta	Salida
1 · Lectura	Los 120 JSONL, con un esquema explícito único para v1 y v2 y <code>value</code> como texto; cinco archivos por micro-lote y trigger de 10 s	<code>spark.readStream</code>	Stream tipado
2 · Deduplicación	Watermark de 60 días sobre <code>event_ts</code> y <code>dropDuplicatesWithinWatermark("event_id")</code>	Structured Streaming	Stream sin duplicados
3 · Bronze	Escritura particionada por <code>event_date</code> , con <code>ingest_ts</code> y <code>source_file</code> , y checkpoint en <code>_checkpoints/</code>	Structured Streaming · Parquet	<code>bronze/usage_events_stream/</code>
4 · Silver	<code>try_cast</code> de <code>value</code> ; imputación de <code>unit</code> según <code>metric</code> ; banderas de D7; join con las dimensiones de recurso y organización	PySpark · Parquet	<code>silver/usage_events/</code>
5 · Gold	<code>org_daily_usage_by_service</code> , <code>genai_tokens_by_org_date</code> y <code>cost_anomaly_mart</code> (MAD, D9)	PySpark · Parquet	<code>gold/<mart>/</code>
6 · Serving	Carga con upsert por clave primaria	Conector de Cassandra para Spark	Tablas de D8

`event_ts` es el campo `timestamp` de la fuente, tipado; de él se deriva `event_date`. La rama de streaming termina en Bronze: la promoción a Silver y Gold se ejecuta por partición de fecha, sobre las fechas que recibieron eventos, con las reglas de §5.6.

6.3 Watermark y datos tardíos (D6)

El dataset no está ordenado por tiempo: cada archivo contiene los 60 días mezclados. En el primer micro-lote ya aparece un evento del 31/08 y el watermark avanza hasta el máximo. Simulación con micro-lotes de cinco archivos:

Watermark	Eventos descartados
1 día	94,2 %
2 días	92,7 %
7 días	84,7 %
30 días	47,9 %
60 días	0 %

Un watermark de 2 días descarta el 93 % de los eventos sin excepción ni registro en el log. Se fija en 60 días, con lo que no se descarta ninguno. La idempotencia no depende del watermark: se apoya en el checkpoint y en un anti-join contra Bronze. A escala real, 60 días de estado no son viables; el histórico se cargaría por batch y el stream en vivo usaría un watermark de minutos, que es la separación que permite Lambda.

6.4 Evolución de esquema (D5)

Versión	Período	Eventos	Campos
v1	03/07/2025 a 17/07/2025	10.800	11 campos base
v2	18/07/2025 a 31/08/2025	32.400	Los de v1, carbon_kg y, en el servicio genai , genai_tokens

Las dos versiones conviven en una sola tabla de Bronze con el esquema de v2: los eventos v1 llevan carbon_kg y genai_tokens en nulo y se conserva schema_version como columna. El corte es limpio, sin solapamiento. genai_tokens aparece en 3.132 de los 4.158 eventos de genai , por lo que el mart genai_tokens_by_org_date no tiene datos anteriores al 18/07.

6.5 Reglas de calidad (D7)

BLOQUEA envía el registro a Quarantine; MARCA lo deja pasar con una bandera en dq_flags .

Regla	Acción	Violaciones medidas
event_id no nulo y único	BLOQUEA	0 (43.200 únicos)
cost_usd_increment >= -0.01	MARCA	211 / 43.200 (0,49 %)
unit no nulo si hay value	MARCA e imputa	2.038 (4,72 %)
value casteable a double	BLOQUEA si falla	0 fallan
currency='USD' ⇒ fx = 1.0	CORRIGE	160 / 160 filas USD
csat ∈ [1,5]	MARCA y anula	40 / 746 (0.0×11, 6.0×28, 7.0×1)
nps_score ∈ [-100,100]	MARCA y anula	1 (valor 101.0)

6.6 Serving query-first (D8)

Consulta (\$7.4)	Tabla	Partition key	Clustering key
1 · Costos y requests diarios	org_daily_usage_by_service	(org_id)	usage_date DESC, service
2 · Top-N servicios, 14 días	org_service_cost_14d	(org_id)	total_cost_usd DESC, service
3 · Tickets críticos y SLA	tickets_by_org_date	(org_id)	date DESC, severity
4 · Revenue mensual en USD	revenue_by_org_month	(org_id)	month DESC
5 · Tokens GenAI por día	genai_tokens_by_org_date	(org_id)	date DESC

org_id es la partition key de todas las tablas porque las cinco consultas filtran por organización: cada consulta lee una sola partición. El Top-N tiene una tabla propia porque Cassandra no ordena por una columna agregada; el total se calcula en Spark y se escribe como clustering key descendente.

7. Lógica MapReduce del flujo batch

Se expresa el mart org_daily_usage_by_service como job MapReduce canónico.

Map — por cada evento de Silver:

```
clave = (org_id, event_date, service)
valor = (cost_usd_increment,
        value si metric = "requests"           else 0,
        value si metric = "cpu_hours"         else 0,
        value si metric = "storage_gb_hours" else 0,
        genai_tokens ?? 0,
        carbon_kg    ?? 0,
        1)                                     # contador
```

Un `value` nulo aporta 0 a la suma.

Combiner — suma componente a componente dentro de cada mapper. Válido porque todas las métricas son sumas, y la suma es asociativa y conmutativa.

Shuffle — agrupa por `(org_id, event_date, service)`. $80 \times 60 \times 6 = 28.800$ claves posibles, de las que el dataset materializa 11.050.

Reduce — suma los vectores parciales y emite una fila del mart:

```
(org_id, usage_date, service, daily_cost_usd, requests,
cpu_hours, storage_gb_hours, genai_tokens, carbon_kg, event_count)
```

Equivalencia en Spark:

```
def metric_sum(metric):
    return F.sum(F.when(F.col("metric") == metric, F.col("value_num")).otherwise(0))

mart = (silver_events
        .groupBy("org_id", "event_date", "service")
        .agg(F.sum("cost_usd_increment").alias("daily_cost_usd"),
            metric_sum("requests").alias("requests"),
            metric_sum("cpu_hours").alias("cpu_hours"),
            metric_sum("storage_gb_hours").alias("storage_gb_hours"),
            F.sum(F.coalesce("genai_tokens", F.lit(0))).alias("genai_tokens"),
            F.sum(F.coalesce("carbon_kg", F.lit(0.0))).alias("carbon_kg"),
            F.count("*").alias("event_count"))
        .withColumnRenamed("event_date", "usage_date"))
```

Correspondencia: el `groupBy().agg()` equivale a este MapReduce. El `groupBy` define la clave del shuffle, el `agg` es el reduce, y Spark aplica agregación parcial en el mapper, que cumple el rol del combiner. La diferencia (clase 03, p. 45) es que MapReduce escribe el resultado de cada trabajo en HDFS con replicación, mientras Spark mantiene los resultados intermedios en memoria y encadena las transformaciones en un DAG con evaluación perezosa. El plan físico de Spark muestra la misma estructura: un `HashAggregate` con sumas parciales, un `Exchange hashpartitioning` por la clave y un `HashAggregate` final.

Sobre el skew: no hay riesgo. La clave más pesada tiene 15 eventos y la mediana es 3, así que ninguna partición domina el tiempo total.

8. Matriz requisito-componente

La matriz está en [matriz_requisito_componente.md](#) y tiene cuatro partes:

Parte	Relación que traza
A	Preguntas del negocio (P1 a P5) → mart en Gold y tabla en Cassandra
B	Requisitos técnicos de la consigna (§4.4) → componente, zona y decisión
C	Las 5V → decisión de arquitectura que responde a cada una

Parte	Relación que traza
D	Objetivos medibles (O1 a O7) → componente y decisión que los cumplen

9. Supuestos, riesgos y decisiones abiertas

9.1 Supuestos

#	Supuesto	Si no se cumple
1	El dataset no cambia entre hoy y el 07/12	Re-correr el notebook de perfilado y revisar D4, D6 y D7, que dependen de cifras medidas
2	<code>credits</code> nulo en <code>billing_monthly</code> significa cero, no "desconocido"	Cambia el cálculo de revenue de la consulta 4
3	Los tickets sin <code>resolved_at</code> están abiertos, no perdidos	Cambia la tasa de resolución y el mart de Soporte
4	Los tipos de cambio de ARS (~0,0015) son reales y no errores de carga	Corregirlos inflaría el revenue argentino por ~650
5	Los <code>resource_id</code> de los eventos siempre existen en <code>resources.csv</code>	Hoy se cumple (400 de 400); igual se implementa un left join con marca de huérfano
6	La proyección de volumen de las 5V es ilustrativa, no una medición	Se declara como supuesto en el documento; no sostiene ninguna decisión por sí sola

9.2 Riesgos y mitigaciones

#	Riesgo	Prob.	Impacto	Mitigación
R1	Un watermark corto descarta el 93 % de los eventos, sin error ni log	Alta	Crítico	D6: watermark de 60 días, con la simulación documentada
R2	El esfuerzo del equipo se desvía hacia la implementación y el documento de diseño queda incompleto	Media	Crítico	Esta entrega es de diseño; la implementación es alcance de la 2. ^a
R3	<code>value</code> declarado como <code>DoubleType</code> pierde el 3,03 % de los datos en silencio	Alta	Alto	D4: leer como string en Bronze y castear en Silver
R4	El revenue queda distorsionado ± 15 % por el tipo de cambio de las facturas en USD	Alta	Alto	D7: forzar el FX a 1,0 para USD, conservando el original
R5	El diagrama deja de coincidir con lo que dice el documento	Media	Alto	Control cruzado antes de congelar; el diagrama se actualiza junto con el texto
R6	Colab se desconecta y se pierde el trabajo	Media	Medio	D2: el Data Lake vive en Drive, no en el disco de Colab
R7	Límites del tier gratuito de AstraDB en la segunda entrega	Baja	Medio	Probar la conexión antes del 16/11; Cassandra en contenedor como plan B
R8	Los archivos Parquet quedan demasiado chicos y degradan la lectura	Media	Bajo	D3: no particionar por servicio; compactar Bronze

R1, R3 y R4 se detectaron midiendo el dataset y están documentados con su cifra en `decisions.md`.

9.3 Decisiones abiertas

Decisiones no tomadas a la fecha de la entrega, con su fecha límite y la opción preferida.

Pregunta	Se decide antes de	Inclinación
¿AstraDB o Cassandra en Docker?	16/11	AstraDB, por la modalidad remota
¿El componente de ML es anomalías o churn?	16/11	Anomalías: reutiliza D9 y alimenta un mart ya pedido
¿SCD tipo 2 en <code>dim_org</code> ?	16/11	No: el dataset no trae historia de cambios de plan
¿Herramienta de visualización?	07/12	Notebook con matplotlib

Pregunta	Se decide antes de	Inclinación
¿Airflow o notebook secuencial?	07/12	Secuencial: Airflow en Colab es overhead sin beneficio

10. Estimación de esfuerzo y recursos

El detalle está en [plan_inicial.md](#).

10.1 Roles

Área	De qué responde	Artefacto principal
Arquitectura	Patrón, diagrama, capacidades transversales, matriz	<code>arquitectura_v1.svg</code> , <code>matriz_requisito_componente.md</code>
Datos y calidad	Inventario, perfil de fuentes, reglas de calidad, diccionario	<code>evidence/profiling_landing.md</code> , §3 del diseño
Data Lake	Zonas, particionamiento, naming, retención, metadatos, promoción	§5 del diseño
Procesamiento	Flujos batch y streaming, esquemas explícitos, lógica MapReduce	§§6 y 7 del diseño
Documento y repo	Estructura, README, convenciones, redacción e integración final	<code>diseno_v1.md</code> , este plan

10.2 Esfuerzo

El esfuerzo se estima en tallas relativas y no en horas. **Alto**: varias sesiones, con discusión de equipo. **Medio**: una o dos sesiones. **Bajo**: una sesión. La tabla cubre los bloques de la primera entrega; los de las entregas siguientes están en §10.4.

Bloque de trabajo	Esfuerzo
Lectura de la consigna y del material de clase	Medio
Perfilado del dataset y validación de hallazgos	Medio
Decisiones de arquitectura y diseño del Data Lake	Alto
Diagrama de arquitectura v1	Medio
Matriz de trazabilidad	Medio
Interpretación del problema, usuarios y objetivos	Bajo
Metadatos de las zonas del Data Lake	Bajo
Flujos batch y streaming, y lógica MapReduce	Medio
Redacción e integración del documento de diseño	Alto
Revisión contra el checklist y ensayo de defensa	Bajo

10.3 Recursos

Recurso	Para qué	Costo	Estado
Google Colab	Ejecución de PySpark en <code>local[*]</code>	gratuito	disponible
Google Drive	Data Lake persistente entre sesiones de Colab	gratuito	disponible
GitHub	Repositorio versionado, privado, con el docente invitado	gratuito	creado
AstraDB	Serving en Cassandra (2.ª entrega)	tier gratuito	a validar antes del 16/11
PySpark 3.5.x	Motor de procesamiento	—	fijado en D2

No hay costos de infraestructura: todo el alcance del proyecto entra en los tiers gratuitos.

10.4 Próximos pasos

Bloques de trabajo posteriores a esta entrega, con la instancia en la que se evalúan y su esfuerzo estimado. El alcance sale de la consigna (§5.6, §6.2 y §7.2).

#	Bloque de trabajo	Entrega	Esfuerzo	Componente o referencia
1	Plan de correcciones a partir del feedback: prioridad, responsable, fecha objetivo y evidencia esperada	Posterior a la 1. ^a	Bajo	Consigna §5.6
2	Validar la conexión con AstraDB y cerrar la decisión de serving	2. ^a · 16/11	Bajo	R7 · decisiones abiertas
3	Ingesta batch de al menos tres maestros a Bronze	2. ^a · 16/11	Medio	src/ingest/batch_masters.py
4	Ingesta streaming de eventos a Bronze, con watermark, deduplicación y checkpoint	2. ^a · 16/11	Alto	src/ingest/stream_events.py
5	Silver de eventos y de al menos un maestro, con joins y tres features	2. ^a · 16/11	Alto	src/silver/conform_events.py , src/silver/features.py
6	Reglas de calidad y Quarantine con muestras	2. ^a · 16/11	Medio	src/quality/rules.py
7	Mart org_daily_usage_by_service en Gold	2. ^a · 16/11	Medio	src/gold/marts.py
8	Keyspace, tabla query-first, carga desde Spark y dos consultas CQL	2. ^a · 16/11	Medio	src/serving/load_astra.py
9	Componente analítico; la opción preferida es anomalías de costo	2. ^a · 16/11	Medio	src/gold/anomalies.py · D9
10	Demostración de idempotencia, pruebas, Quickstart y evidencias de ejecución	2. ^a · 16/11	Medio	tests/ , evidence/ , README
11	Gobierno preliminar y backlog final priorizado	2. ^a · 16/11	Bajo	Consigna §6.2
12	Maestros restantes en Bronze y Silver	Final · 07/12	Medio	src/ingest/batch_masters.py
13	Marts restantes y sus tablas de serving, para responder P3 a P5	Final · 07/12	Alto	src/gold/marts.py , src/serving/load_astra.py
14	Gobierno, linaje, seguridad y observabilidad completos; diccionario de datos	Final · 07/12	Medio	D11
15	Presentación ejecutiva, video y defensa oral	Final · 07/12	Medio	Consigna §7.5